

## المشروع النصفي لمقرر البيانات الضخمة

بناء خط بيانات هجين لمعالجة بيانات الطلاب

Python Batch Loading | Apache Spark | MongoDB | ELT | Data Quality | Idempotency | Upsert

|                                             |                        |
|---------------------------------------------|------------------------|
| البيانات الضخمة - العملي                    | المقرر                 |
| طلبة المستوى الرابع - تخصص الذكاء الاصطناعي | الفئة                  |
| م. عمر أبوسند                               | المحاضر                |
| المحاضرة القادمة                            | موعد التسليم والمناقشة |

وثيقة التكلفة الرسمية

## 1. فكرة المشروع

يهدف المشروع إلى بناء خط بيانات هجين يستقبل ملف بيانات الطلبات غير النظيف الذي ساقدمه لكم، ثم يختار طريقة التحميل المناسبة تلقائيًا حسب حجم الملف: تحميل دفعي باستخدام Python للملفات الصغيرة، أو معالجة متوازية باستخدام Apache Spark للملفات الكبيرة. بعد ذلك يطبق المشروع نمط ELT؛ حيث تُحمّل البيانات الخام أولاً إلى MongoDB دون حذف أو تنظيف مسبق، ثم تُحلّ وتُنظف وتُصنّف إلى بيانات قابلة للاستخدام وبيانات يجب عزلها.

**المبدأ الأساسي:** لا يجوز إسقاط السجلات السيئة أثناء التحميل الأولي. كل سجل يجب أن يصل إلى Raw، ثم ينتهي لاحقاً إما في Validated أو Quarantine مع سبب واضح.

## 2. مخرجات التعلم المتوقعة

- اختيار أسلوب المعالجة المناسب بناءً على حجم البيانات والموارد المتاحة.
- تنفيذ Batch Loading دون تحميل الملف كاملاً في الذاكرة.
- استخدام PySpark لقراءة ملف كبير ومعالجته وكتابته بالتوازي.
- تصميم خط ELT يبدأ بتحميل البيانات الخام قبل تنفيذ قواعد التحويل والجودة.
- التمييز بين الخطأ القابل للتصحيح والخطأ الذي يتطلب العزل.
- قياس الزمن، ومعدل المعالجة، وعدد الدفعات أو التقسيمات، وتفسير النتائج.
- توثيق خط البيانات وتشغيله بطريقة قابلة لإعادة التنفيذ والتقييم.
- تطبيق Idempotency وUpsert لضمان أن إعادة تشغيل نفس البيانات لا تنشئ سجلات مكررة ولا تغيّر الحالة النهائية بصورة غير صحيحة.

## 3. البيانات المقدمة

لديكم ملف CSV ضخم خاص ببيانات متجر إلكتروني. يحتوي الملف على بيانات سليمة، وأخطاء قابلة للتصحيح آلياً، وأخطاء لا يمكن تصحيحها بأمان. لا يُطلب منكم اختيار مجال جديد في هذا المشروع؛ اختيار مجال مختلف سيكون ضمن المشروع النهائي.

| الفئة                   | الوصف                                                                          | المصير                             |
|-------------------------|--------------------------------------------------------------------------------|------------------------------------|
| بيانات سليمة            | قيم صحيحة ومتوافقة مع الشكل المتوقع.                                           | تنتقل إلى Validated دون تعديل.     |
| أخطاء قابلة للتصحيح     | مثل الأرقام العربية، السعر النصي، المسافات، بعض أخطاء البريد والهاتف والتاريخ. | تُصحح آلياً مع حفظ أثر التصحيح.    |
| أخطاء غير قابلة للتصحيح | مثل معرف مفقود، JSON تالف، تاريخ مستحيل، أو قيم جوهرية مجهولة.                 | تنتقل إلى Quarantine مع سبب العزل. |

## 4. المعمارية المطلوبة

| المرحلة | العملية             | المطلوب                                                                                                            |
|---------|---------------------|--------------------------------------------------------------------------------------------------------------------|
| 1       | اكتشاف الملف        | قراءة المسار والحجم وإنشاء run_id للعملية.                                                                         |
| 2       | اختيار المحرك       | Python Batch إذا كان الملف صغيراً، وPySpark إذا تجاوز الحد المحدد.                                                 |
| 3       | Raw Load            | تحميل جميع السجلات إلى orders_raw كما وصلت، دون فلترة جودة.                                                        |
| 4       | Transform & Quality | تطبيق الأنواع والصيغ وتطبيق قواعد التصحيح والتحقق.                                                                 |
| 5       | Classification      | تصنيف كل سجل إلى Valid أو Corrected أو Quarantined.                                                                |
| 6       | Final Load          | استخدام Upsert لكتابة السجلات السليمة/المصححة في orders_validated، وكتابة غير القابل للتصحيح في orders_quarantine. |
| 7       | Idempotency Check   | إعادة تشغيل نفس المدخل والتحقق من عدم زيادة Duplicate business orders_validated records.                           |

| جامعة الرازي   مقرر البيانات الضخمة - العملي |         | المشروع النصفي                                                    |
|----------------------------------------------|---------|-------------------------------------------------------------------|
| المرحلة                                      | العملية | المطلوب                                                           |
| 8                                            | Metrics | حفظ زمن التنفيذ والعدادات والإعدادات في ملف .reports/results.json |

التدفق المنطقي:

Provided Dirty CSV

|

v

File Router: size <= threshold ?

|

|

v

v

Python Batch

PySpark

|

|

+-----+-----+

v

orders\_raw

|

v

Cleaning + Validation

|

|

|

+-----> orders\_quarantine

v

Idempotent Upsert

|

v

orders\_validated

Metrics -> reports/results.json

5. آلية العمل الفردي والجماعي

| النمط  | العدد      | الشرط                                                                                                  |
|--------|------------|--------------------------------------------------------------------------------------------------------|
| فردى   | طالب واحد  | تنفيذ جميع المتطلبات الأساسية، مع جودة كود واختبارات وتحليل نتائج كافٍ للحصول على الدرجة الكاملة.      |
| مجموعة | طالبان فقط | تنفيذ جميع المتطلبات الأساسية، بالإضافة إلى مسار متقدم واحد إلزامى من المسارات المحددة في هذه الوثيقة. |

**تنبيه للمجموعات:** المجموعة التي لا تنفذ مسارًا متقدمًا كاملاً وموثقًا لا تحصل على درجات الجزء المتقدم، حتى لو تم تقسيم العمل الأساسي بين الطالبين.

6. المتطلبات الأساسية الإلزامية

6.1 إنشاء عينة صغيرة قابلة لإعادة الإنتاج

لأن الملف المقدم ضخ، يجب إنشاء سكربت مستقل يستخرج عينة صغيرة منه للاختبار. يمنع إنشاء العينة يدويًا بواسطة Excel. يجب أن يكون عدد الصفوف أو حجم العينة قابلاً للتغيير من الإعدادات.

python create\_small\_sample.py --input orders\_huge\_mixed\_quality.csv --rows 100000

## 6.2 الموجة التلقائي للمحرك File Router

يجب أن يحتوي المشروع على نقطة تشغيل واحدة تفحص حجم الملف وتقرر المحرك المستخدم. الحد الفاصل يوضع في ملف إعدادات أو متغير بيئة، ويجب تبرير قيمته في التقرير.

```
SMALL_FILE_THRESHOLD_MB = 200
```

```
if file_size_mb <= SMALL_FILE_THRESHOLD_MB:
    engine = "python_batch"
else:
    engine = "pyspark"
```

- يجب طباعة حجم الملف والمحرك المختار وسبب الاختيار.
- يجب إثبات عمل المسارين باستخدام العينة الصغيرة والملف الكبير.
- لا يجوز كتابة برنامجين منفصلين دون وجود نقطة تشغيل أو Router يختار بينهما.

## 6.3 تحميل الملفات الصغيرة باستخدام Python Batch

- قراءة CSV بصورة Streaming باستخدام csv module أو أداة مكافئة.
- تجميع السجلات في دفعات قابلة للضبط، ثم استخدام insert\_many.
- عدم استخدام list(reader) أو تحميل الملف كاملاً إلى الذاكرة.
- طباعة رقم الدفعة، وعدد السجلات، والزمن، ومعدل الإدخال.
- معالجة خطأ الدفعة وتسجيله دون إخفاء سبب الفشل.

## 6.4 تحميل الملفات الكبيرة باستخدام PySpark

- استخدام SparkSession و DataFrame API، وليس Pandas.
- استخدام Schema ثابتة بدل inferSchema في الملف الكبير.
- قراءة الحقول الحساسة في Raw ك String للحفاظ على القيم غير النظيفة.
- كتابة البيانات إلى MongoDB بالتوازي باستخدام MongoDB Spark Connector.
- عدم استخدام repartition دون تبرير؛ وإذا استُخدمت يجب إظهار أثرها في explain و Spark UI.
- تسجيل عدد Input Partitions، وزمن التنفيذ، ومعدل السجلات في الثانية.

## 6.5 التحميل الخام وفق ELT

يجب تحميل البيانات كاملة أولاً إلى orders\_raw قبل تطبيق قواعد التنظيف. الهدف من Raw هو حفظ نسخة قابلة للتتبع من البيانات كما وصلت.

| الحقل             | الغرض                                                      |
|-------------------|------------------------------------------------------------|
| run_id            | معرف فريد لكل عملية تشغيل.                                 |
| source_file       | اسم أو مسار الملف المصدر.                                  |
| source_row_number | رقم الصف إن أمكن.                                          |
| ingested_at       | وقت التحميل.                                               |
| engine_used       | python_batch أو pyspark.                                   |
| raw_record        | السجل الخام أو الحقول الخام دون تحويل يفقد القيمة الأصلية. |

## 6.6 قواعد التنظيف الآلي

يجب تنفيذ ثماني قواعد تصحيح آلي على الأقل. لا تُصحح القيمة إلا عندما تكون قاعدة التحويل واضحة ولا تعتمد على التخمين.

| القاعدة           | مثال                  | المعالجة المتوقعة                              |
|-------------------|-----------------------|------------------------------------------------|
| الأرقام العربية   | ١٢٣ أو ٥٠٠٠           | تحويلها إلى أرقام لاتينية ثم إلى النوع الصحيح. |
| رمز أو اسم العملة | 5000 ريال، ريال يماني | إزالة النص وتوحيد العملة إلى YER.              |
| فواصل الآلاف      | 125,000.00            | إزالة فواصل الآلاف والتحويل إلى رقم.           |
| السعر بالكلمات    | ألفان، خمسة آلاف      | تحويل القيم المعروفة المحددة فقط.              |
| رقم الهاتف        | 4567 123 77 967+      | إزالة المسافات وتوحيد صيغة الرقم عند وضوحها.   |
| البريد الإلكتروني | user@@mail..com       | إصلاح التكرار الواضح فقط؛ وإلا يعزل السجل.     |

| القاعدة             | مثال                     | المعالجة المتوقعة                                         |
|---------------------|--------------------------|-----------------------------------------------------------|
| التاريخ             | 2025-01-31 أو 31/01/2025 | تحويل التاريخ الصحيح إلى صيغة قياسية.                     |
| المسافات والمرادفات | مؤكد ، مدفوع             | Trim وتوحيد القيم إلى القاموس القياسي.                    |
| إجمالي الطلب        | إجمالي غير مطابق         | إعادة الحساب من العناصر والتوصيل إذا كانت المكونات صالحة. |

### 6.7 أثر التصحيح Audit Trail

كل سجل تم تصحيحه يجب أن يحتفظ بأثر يوضح الحقول التي تغيرت. لا يكفي حفظ القيمة النهائية فقط.

```
"quality_status": "corrected",
"corrections": [
{
"field": "customer_email",
"original_value": "user@@mail..com",
"corrected_value": "user@mail.com",
"rule_code": "EMAIL_REPEATED_SYMBOLS"
}
]
```

### 6.8 العزل Quarantine

كل سجل لا يمكن تصحيحه بأمان يجب أن ينتقل إلى orders\_quarantine. يمنع حذف السجل أو تجاهله بصمت.

| رمز الخطأ                   | سبب العزل                                     |
|-----------------------------|-----------------------------------------------|
| MISSING_ORDER_ID            | معرف الطلب مفقود ولا يمكن استنتاجه.           |
| MISSING_CUSTOMER_ID         | معرف العميل مفقود.                            |
| INVALID_IMPOSSIBLE_DATE     | تاريخ غير منطقي أو مستحيل.                    |
| CORRUPTED_ITEMS_JSON        | JSON ناقص أو غير قابل للتحليل.                |
| EMPTY_ITEMS                 | لا توجد عناصر للطلب.                          |
| UNKNOWN_PRICE               | السعر الأصلي غير موجود أو غير قابل للاستنتاج. |
| AMBIGUOUS_NEGATIVE_VALUE    | كمية أو مبلغ سالب لا يمكن تحديد معناه.        |
| DUPLICATE_ORDER_ID          | تكرار يحتاج سياسة دمج أو مراجعة.              |
| MULTIPLE_CONFLICTING_ERRORS | عدة أخطاء جوهرية تمنع التصحيح الآمن.          |

### 6.9 المجموعات المطلوبة في MongoDB

| Collection        | المحتوى                                             | ملاحظة                                                                              |
|-------------------|-----------------------------------------------------|-------------------------------------------------------------------------------------|
| orders_raw        | جميع السجلات كما وصلت، مع بيانات المصدر والتشغيل.   | لا Validator ولا Unique Index يمنعان التحميل.                                       |
| orders_validated  | السجلات السليمة والسجلات المصححة القابلة للاستخدام. | Schema Validation + Unique Index على order_id، والكتابة باستخدام Idempotent Upsert. |
| orders_quarantine | السجلات التي لم يمكن تصحيحها بأمان.                 | يجب أن تحتوي error_codes و error_details والسجل الخام.                              |

### 6.10 متطلبات إعادة التشغيل الموثوق - إلزامي للجميع

- يجب اعتماد Stable Business Key واضح، ويُستخدم order\_id كمفتاح العمل الأساسي في بيانات الطلبات.
- بعد معالجة التكرارات، يجب إنشاء Unique Index على order\_id داخل orders\_validated.
- يجب أن تكون الكتابة إلى orders\_validated باستخدام Upsert: السجل الجديد يُضاف، والسجل الموجود يُحدَّث وفق سياسة واضحة، بدل الاعتماد على check-then-insert.
- يجب إثبات Idempotency عمليًا بإعادة تشغيل نفس الملف أو نفس مجموعة السجلات مرة ثانية؛ يجب ألا يزيد عدد Business Records في orders\_validated وألا تتغير الحالة النهائية بعد أول تشغيل ناجح.

• orders\_raw طبقة تتبع تاريخية؛ يجوز أن تحتفظ بمحاولة إدخال جديدة لكل run\_id. معيار Idempotency هنا يخص الحالة التجارية النهائية في orders\_validated، ولا يعني حذف تاريخ التحميل من Raw.

• إذا استخدم المشروع عملية تراكمية مثل inc\$، فيجب استخدام operation\_id أو event\_id فريد لمنع تطبيق العملية نفسها أكثر من مرة.

## 6.11 قاعدة الاتساق الأساسية

شرط قبول: لكل run\_id يجب أن يكون كل سجل خام قد انتهى إلى نتيجة معالجة واحدة فقط: Valid/Corrected أو Quarantine. أما orders\_validated فهي حالة نهائية فريدة حسب order\_id وقد تستقبل Upsert من أكثر من تشغيل.

$$\text{run\_raw\_count} = \text{run\_valid\_count} + \text{run\_corrected\_count} + \text{run\_quarantine\_count}$$

## 6.12 القياسات المطلوبة

| المقياس                  | الوصف                                                   |
|--------------------------|---------------------------------------------------------|
| run_id                   | معرف التشغيل.                                           |
| file_name / file_size_mb | اسم الملف وحجمه.                                        |
| engine_used              | المحرك الذي تم اختياره.                                 |
| rows_read                | السجلات المقروءة.                                       |
| raw_loaded               | السجلات التي وصلت إلى Raw.                              |
| valid_count              | السجلات السليمة دون تعديل.                              |
| corrected_count          | السجلات المصححة.                                        |
| quarantine_count         | السجلات المعزولة.                                       |
| elapsed_seconds          | الزمن الكلي.                                            |
| throughput               | عدد السجلات في الثانية.                                 |
| batch_size / partitions  | إعدادات المحرك المستخدم.                                |
| error_case_counts        | عدد كل نوع من الأخطاء.                                  |
| inserted_count           | عدد السجلات الجديدة التي أضافها Upsert.                 |
| updated_count            | عدد السجلات الموجودة التي تم تحديثها.                   |
| unchanged_count          | عدد السجلات التي أعيدت مع نفس الحالة ولم تتطلب تغييرًا. |

## 7. المتطلبات المتقدمة للمجموعات

كل مجموعة مكونة من طالبين ملزمة بتنفيذ مسار متقدم واحد كامل من المسارين التاليين. يجب اختيار المسار وتسجيله لدى قبل البدء. تنفيذ جزء بسيط من أكثر من مسار لا يعادل إكمال مسار واحد. يمكن للطالب الفردي تنفيذ المسار B اختياريًا كمسار تميز لإظهار عمق أكبر في تصميم خط البيانات.

### المسار A: تشغيل Spark كعنقود مستقل

- تشغيل Spark Master و Worker واحد على الأقل على جهازين فعليين أو جهازين افتراضيين منفصلين.
- تشغيل التطبيق باستخدام spark://MASTER\_IP:7077، وليس الوضع المحلي.
- توحيد إصدارات Java و Python و Spark و MongoDB Connector على العقد.
- جعل ملف البيانات متاحًا للعقد بطريقة موثقة، مثل Shared Folder أو تخزين شبكي مناسب.
- إثبات ظهور Worker في Spark Master UI وظهور Executors و Tasks أثناء التنفيذ.
- تشغيل معالجة فعلية على مليون سجل على الأقل، مع مقارنة زمنها بتشغيل الوضع المحلي على نفس البيانات.
- تسليم لقطات واجهة Cluster وشرح توزيع الأدوار بين Master و Workers.

لا يُطلب: لا يلزم إعداد Hadoop أو HDFS أو YARN؛ المطلوب Spark Standalone Cluster فقط.

المسار B: التحميل التزايدي والموثوقية المتقدمة

- يبدأ المسار من المتطلبات الأساسية الإلزامية لـ Idempotency وUpsert، ثم يطوّر ها إلى معالجة Incremental فعلية.
- تنفيذ Initial Load للبيانات الأساسية، ثم استخدام ملف Delta يحتوي فقط على سجلات جديدة أو معدلة بدل إعادة معالجة المصدر الكامل في كل تشغيل.
- تحديد آلية Incremental واضحة مثل updated\_at أو version أو watermark/آخر قيمة معالجة، وتوثيق كيفية اكتشاف السجلات الجديدة والمعدلة.
- تطبيق Upsert على Delta فقط، مع تسجيل inserted\_count وupdated\_count وunchanged\_count لكل تشغيل.
- إعادة تشغيل نفس Delta مرة ثانية يجب أن تكون Idempotent: لا Duplicate ولا زيادة غير صحيحة في orders\_validated ولا إعادة تطبيق تحديث تراكمي سبق تنفيذه.
- تنفيذ Version Handling أو updated\_at عند تعارض التحديثات لتحديد النسخة الأحدث. وإذا استُخدمت عمليات تراكمية مثل inc\$، فيجب استخدام operation\_id/event\_id فريد.
- إثبات المسار بثلاث تجارب موثقة: Initial Load، ثم Delta أولى تحتوي Insert + Update، ثم إعادة تشغيل نفس Delta لإثبات Idempotency وعدم تكرار التأثير.

| المسار                                          | الحد الأدنى للقبول                                                                                                                                                                                       |
|-------------------------------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| المسار A - عنقود Spark                          | تشغيل Master و Worker على جهازين، واستخدام spark://، وإرفاق دليل من واجهة Spark UI، مع مقارنة التشغيل المحلي وتشغيل العنقود.                                                                             |
| المسار B - التحميل التزايدي والموثوقية المتقدمة | المتطلبات الأساسية لـ Idempotency وUpsert، ثم Initial Load وملفات Delta فقط، وآلية updated_at/version/watermark، ومعالجة الإصدارات، وقياس Insert/Update/Unchanged، وإعادة تشغيل Delta دون تكرار التأثير. |

## 8. هيكل المشروع المقترح

```

midterm-data-pipeline/
|-- README.md
|-- requirements.txt
|-- config/
|   |-- settings.py
|-- data/
|   |-- .gitkeep
|-- src/
|   |-- main.py
|   |-- file_router.py
|   |-- create_small_sample.py
|   |-- batch_loader.py
|   |-- spark_loader.py
|   |-- quality_rules.py
|   |-- elt_pipeline.py
|   |-- incremental_loader.py # Path B / distinction
|   |-- mongo_setup.py
|   |-- metrics.py
|-- tests/
|   |-- test_cleaning_rules.py
|   |-- test_classification.py
|-- reports/
|   |-- results.md
|   |-- screenshots/

```

```
-- docs/
-- architecture.md
```

## 9. متطلبات الكود والتشغيل

- يجب أن يعمل المشروع من أمر رئيسي واضح موثق في README.
- جميع المسارات والإعدادات المهمة توضع في Config أو Environment Variables، ولا تُوزع داخل الكود.
- يجب استخدام try/finally لإغلاق Spark و MongoDB بصورة سليمة.
- يجب أن تظهر رسائل تقدم مفهومة، وألا يبقى البرنامج صامتاً أثناء التنفيذ الطويل.
- يجب فصل منطق التحميل عن منطق التنظيف عن منطق الاتصال بقاعدة البيانات.
- يجب إضافة اختبارات لقواعد التنظيف والتصنيف الأساسية.
- يمنع تعديل ملف البيانات يدوياً لتسهيل النتائج.

## 10. سيناريو العرض العملي

| الخطوة | العرض                       | دليل النجاح                                                                                              |
|--------|-----------------------------|----------------------------------------------------------------------------------------------------------|
| 1      | تشغيل العينة الصغيرة        | يجب أن يختار Router محرك Python Batch.                                                                   |
| 2      | عرض orders_raw              | إثبات أن البيانات حُمِلت قبل التنظيف.                                                                    |
| 3      | تشغيل قواعد الجودة          | عرض مثال لسجل سليم، وسجل مصحح، وسجل معزول.                                                               |
| 4      | تشغيل الملف الكبير          | يجب أن يختار Router محرك PySpark.                                                                        |
| 5      | عرض Spark UI                | إظهار Jobs و Stages و Tasks و Partitions.                                                                |
| 6      | عرض Collections النهائية    | orders_validated و orders_quarantine، مع ملف reports/results.json.                                       |
| 7      | عرض المقاييس                | الزمن، السرعة، العدادات، وأنواع الأخطاء.                                                                 |
| 8      | اختبار Idempotency و Upsert | إعادة تشغيل نفس المدخل وإثبات عدم زيادة orders_validated، ثم تعديل سجل واحد وإظهار Update Duplicate دون. |
| 9      | المسار المتقدم للمجموعة     | عرض دليل التنفيذ والنتائج الخاصة بالمسار المختار.                                                        |

## 11. ملفات التسليم

- رابط مستودع GitHub منظم ويحتوي الكود الكامل.
- README يتضمن متطلبات التشغيل، الإعداد، والأوامر، وبنية المشروع.
- تقرير نتائج مختصر يتضمن مقارنة Python Batch و PySpark.
- ملف requirements.txt أو تعليمات تثبيت واضحة.
- لقطات من MongoDB Compass و Spark UI.
- ملف reports/results.json يثبت المقاييس والإعدادات ونتيجة كل تشغيل.
- دليل إلزامي لاختبار Idempotency و Upsert: تشغيل أول، ثم إعادة تشغيل نفس البيانات دون Duplicate، ثم مثال Update لسجل موجود.
- للمجموعة: دليل المسار المتقدم المختار ونتائجه. وفي المسار B يجب إرفاق نتائج التشغيل الأول، وإعادة تشغيل نفس Delta، وتشغيل Delta جديدة توضح Insert + Update دون تكرار.

## 12. معايير التقييم - 10 درجات

| البند                         | الدرجة | معايير التقييم                                                  |
|-------------------------------|--------|-----------------------------------------------------------------|
| تصميم المعمارية و File Router | 0.75   | اختيار تلقائي صحيح، إعدادات واضحة، وتبرير الحد الفاصل.          |
| Python Batch Loader           | 0.75   | قراءة Streaming، دفعات، قياسات، ومعالجة أخطاء.                  |
| PySpark Loader                | 1.25   | Schema، Partitions، كتابة متوازية، وعدم إضافة Shuffle غير مبرر. |



| جامعة الرازي   مقرر البيانات الضخمة - العملي                                                                                                       |        | المشروع النصفي                                                                                                                     |
|----------------------------------------------------------------------------------------------------------------------------------------------------|--------|------------------------------------------------------------------------------------------------------------------------------------|
| البند                                                                                                                                              | الدرجة | معايير التقييم                                                                                                                     |
| Raw Layer و ELT                                                                                                                                    | 1      | تحميل كامل قبل التنظيف وحفظ بيانات المصدر والتشغيل.                                                                                |
| التنظيف الآلي و Audit Trail                                                                                                                        | 1.25   | ثمانية قواعد على الأقل مع حفظ أثر التصحيح.                                                                                         |
| Quarantine والتصنيف                                                                                                                                | 1      | أسباب واضحة وعدم فقدان سجلات واتساق عدادات كل run_id.                                                                              |
| Upsert و Idempotency                                                                                                                               | 1      | اعتماد مفتاح عمل ثابت (Stable Business Key)، وفهرس فريد (Unique Index)، واستخدام Upsert، مع إثبات إعادة تشغيل أمانة دون Duplicate. |
| القياسات والمقارنة                                                                                                                                 | 0.75   | تسجيل الزمن ومعدل المعالجة (Throughput) وإعدادات Batch/Partitions و إعدادات Insert/Update/Unchanged، مع تحليل مختصر.               |
| جودة الكود والاختبارات والتوثيق                                                                                                                    | 1      | تنظيم، README، Config، واختبارات أساسية.                                                                                           |
| اكتمال التنفيذ والعرض العملي                                                                                                                       | 1.25   | إمكانية تشغيل المشروع أمامي وشرح القرارات والنتائج والإجابة عن الأسئلة التقنية.                                                    |
| حد المجموعة دون المسار المتقدم: إذا سَلَّم طالبان المشروع كمجموعة دون إكمال المسار A أو المسار B كاملاً، فإن الحد الأعلى لدرجة المشروع هو 8 من 10. |        |                                                                                                                                    |

### 13. حالات الخصم أو عدم القبول

- تحميل الملف الكبير كاملاً في قائمة Python أو DataFrame Pandas.
- تنظيف البيانات قبل إدخالها إلى orders\_raw.
- الكتابة إلى orders\_validated بطريقة Insert فقط دون Upsert/Unique Business Key، أو فشل إعادة التشغيل بسبب Duplicate/تغيير غير صحيح في الحالة النهائية.
- حذف السجلات السيئة دون تخزينها في Quarantine أو توضيح السبب.
- استخدام Spark بالاسم فقط بينما المعالجة الحقيقية تتم تسلسلياً في Python.
- استخدام الوضع المحلي في مسار Cluster الخاص بالمجموعة.
- وجود نفس المشروع لمجموعتين يتم إلغاء الدرجة للمجموعتين.
- عدم قدرة أعضاء المجموعة على شرح الأجزاء المسلمة.
- عدم إمكانية تشغيل المشروع من التعليمات المرفقة.
- تعديل ملف البيانات يدوياً أو تغيير الأخطاء لإظهار نتائج أفضل.

### 14. قائمة تحقق قبل التسليم

| تم                       | البند                                                                                                                                                 |
|--------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------|
| <input type="checkbox"/> | العينة الصغيرة تعمل ويختار النظام Python Batch.                                                                                                       |
| <input type="checkbox"/> | الملف الكبير يعمل ويختار النظام PySpark.                                                                                                              |
| <input type="checkbox"/> | كل السجلات تصل أولاً إلى orders_raw.                                                                                                                  |
| <input type="checkbox"/> | تم تنفيذ ثمانية قواعد تنظيف على الأقل.                                                                                                                |
| <input type="checkbox"/> | السجلات المصححة تحتوي Audit Trail.                                                                                                                    |
| <input type="checkbox"/> | السجلات غير القابلة للتصحيح موجودة في Quarantine مع الأسباب.                                                                                          |
| <input type="checkbox"/> | تم التحقق من اتساق عدادات كل run_id وفق معادلة القسم 6.11.                                                                                            |
| <input type="checkbox"/> | تم تسجيل الزمن والسرعة والإعدادات في reports/results.json.                                                                                            |
| <input type="checkbox"/> | تم إثبات Upsert و Idempotency: إعادة تشغيل نفس البيانات لا تزيد orders_validated، وتحديث سجل موجود لا ينشئ Duplicate.                                 |
| <input type="checkbox"/> | README يشرح التنبيهات والتشغيل.                                                                                                                       |
| <input type="checkbox"/> | المجموعة أكملت المسار A أو B كاملاً؛ وإذا اختير المسار B تم إثبات Incremental Loading باستخدام Delta و Version Handling وإعادة تشغيل Delta دون تكرار. |

**الهدف من المشروع:** المطلوب ليس فقط تشغيل كود ينقل البيانات، بل بناء خط يمكن تفسير قراراته، وتتبع سجلاته، وقياس أدائه، وعدم فقدان البيانات السيئة.